

Inteligencia Artificial en la Economía del Conocimiento

Tutorial de inmersión profunda en Ide & Talamàs (2025, *JPE*)

Alejandro Ventura — ai-05-ide

Fuente: arXiv:2312.05481v11

Contenido

I	La pregunta, el modelo y el mundo sin IA	2
1	Cómo leer este tutorial	2
2	La pregunta del paper	2
3	El modelo	3
3.1	Primitivas	3
3.2	Organizaciones pre-IA	3
3.3	Beneficios	3
3.4	Notación de conjuntos	4
4	El benchmark sin IA (Proposición 1)	4
4.1	De dónde sale cada pieza	4
4.2	Una identidad útil	5
4.3	Ejemplo resuelto: G uniforme y $h = 1/2$	5
4.4	Dos lecturas económicas que usaremos después	5
II	La IA autónoma: Proposiciones 2, 3 y 4	6
5	Qué agrega la IA al modelo	6
6	Proposición 2: el equilibrio con IA autónoma	6
6.1	De dónde sale cada fórmula	7
6.2	Por qué la IA no puede quedarse fuera de las organizaciones	7
7	Ejemplo resuelto: IA básica con G uniforme y $h = 1/2$	7
8	Proposición 3: la IA reordena las ocupaciones	8
9	Proposición 4: qué pasa con los que no cambian de ocupación	8
III	Proposición 5: ¿quién gana con la IA autónoma?	9

10 El enunciado	9
11 Los dos efectos	9
12 El umbral, en forma cerrada	10
13 Tabla de resultados (uniforme, $h = 1/2$)	10
IV Proposición 6 y la trampa: ¿autonomía o capacidad?	10
14 IA no autónoma: el modelo cambia en un solo supuesto	10
15 La trampa de la semana	11

Part I

La pregunta, el modelo y el mundo sin IA

1 Cómo leer este tutorial

El paper tiene una arquitectura muy limpia que conviene tener en la cabeza desde el inicio:

- (1) **Un modelo de jerarquías de conocimiento** (Garicano, 2000; Fuchs, Garicano y Rayo, 2015): los humanos se organizan en *trabajadores* que hacen el trabajo rutinario y *solucionadores* que resuelven las excepciones.
- (2) **Un benchmark sin IA** (Proposición 1), que no es nuevo pero es la vara contra la que se mide todo.
- (3) **La IA como otro “tipo” de agente**: compute que se convierte en agentes con conocimiento z_{AI} .
- (4) **Dos dimensiones de la IA**, que es la idea que más nos importa:
 - *capacidad*: cuánto sabe la IA, z_{AI} (“básica” si z_{AI} cae donde estaban los trabajadores, “avanzada” si cae donde estaban los solucionadores);
 - *autonomía*: si la IA puede producir por sí sola (co-trabajador y co-piloto) o solo asesorar (co-piloto).
- (5) **Dos resultados distributivos**: la Proposición 5 (IA autónoma) y la Proposición 6 (IA no autónoma).

La trampa de esta semana consiste justamente en colapsar el punto (4) a una sola dimensión. Volveremos a ello en la Parte IV; por ahora, lo único que necesitas es no olvidar que **hay dos ejes**.

2 La pregunta del paper

Cuando llega una IA capaz de hacer trabajo intelectual, ¿quiénes ganan y quiénes pierden según cuánto saben, y cómo cambia la respuesta según si la IA puede trabajar por su cuenta o solo aconsejar a humanos?

El *tema* es “IA y desigualdad”. La *pregunta* es más precisa: el paper quiere saber cómo la IA reordena *quién trabaja con quién* dentro de las organizaciones y cómo eso mueve los salarios a lo largo de toda la distribución de conocimiento. La motivación empírica es una contradicción: algunos estudios encuentran que la IA ayuda sobre todo a los menos calificados (p.ej., Brynjolfsson et al., 2025, en atención al cliente) y otros que beneficia más a los más calificados. El paper propone que ambas cosas pueden ser ciertas dependiendo de la capacidad y la autonomía de la IA.

3 El modelo

3.1 Primitivas

- Una masa unitaria de humanos. Cada uno tiene una unidad de tiempo y un conocimiento $z \in [0, 1]$, con distribución G y densidad g continua y **estrictamente positiva**. El conocimiento es observable.
- Cada oportunidad de producción trae un problema de dificultad $x \sim U[0, 1]$. Si quien lo enfrenta sabe más que la dificultad ($z > x$), lo resuelve y produce 1 unidad. Por eso z **es la probabilidad de resolver un problema por cuenta propia**.
- Las oportunidades de producción son abundantes: el recurso escaso es el tiempo (y, luego, el compute).

3.2 Organizaciones pre-IA

Firma de una capa. Un *productor independiente* con conocimiento z produce, en esperanza, z .

Firma de dos capas. Un *solucionador* s y n *trabajadores* con conocimiento z . El trabajador intenta el problema; si falla (probabilidad $1 - z$), le pregunta al solucionador, y cada pregunta consume $h \in (0, 1)$ unidades del tiempo del solucionador, *sepa o no la respuesta*. Si $s > x$, el problema se resuelve.

La firma de dos capas contrata exactamente los trabajadores necesarios para usar todo el tiempo del solucionador:

$$h n(z) (1 - z) = 1 \implies n(z) = \frac{1}{h(1 - z)}. \quad (1)$$

Intuición. Trabajadores más sabios preguntan menos, así que cada solucionador puede supervisar a más de ellos: $n'(z) > 0$. Ese es el canal por el cual *el conocimiento del trabajador libera tiempo del solucionador*.

La producción esperada de un equipo $(s; z)$ es $n(z)s$: cada uno de los $n(z)$ problemas se resuelve si *alguien* del equipo lo sabe, y como el solucionador sabe más que el trabajador, eso ocurre con probabilidad s .

3.3 Beneficios

Normalizando el precio del producto a 1 y llamando $w(\cdot)$ al salario,

$$\Pi_1 = z - w(z), \quad (2)$$

$$\Pi_2^{nA}(s, z) = n(z) [s - w(z)] - w(s), \quad z \leq s. \quad (3)$$

Las firmas son competitivas y hay libre entrada, así que en equilibrio *todas ganan cero* y ninguna podría ganar algo positivo cambiando de estructura o de contratados.

3.4 Notación de conjuntos

Símbolo	Significado
$\mathcal{W}, \mathcal{I}, \mathcal{S}$	conjuntos de trabajadores, productores independientes y solucionadores humanos
$m(z)$	conocimiento del solucionador asignado al trabajador z (<i>matching</i>)
$e(s) = m^{-1}(s)$	conocimiento del trabajador asignado al solucionador s (<i>employee function</i>)
$B \preceq B'$	" B está por debajo de B' ": $\sup B \leq \inf B'$
$\tilde{z}$	frontera trabajador/solucionador pre-IA (cuando $\mathcal{I} = \emptyset$)

4 El benchmark sin IA (Proposición 1)

Proposición 1 (Ide y Talamàs, Prop. 1; Fuchs et al., 2015). *Sin IA existe un único equilibrio, que es eficiente y tiene:*

- *estratificación ocupacional:* $\mathcal{W} \preceq \mathcal{I} \preceq \mathcal{S}$;
- *emparejamiento positivo (PAM):* m es estrictamente creciente;
- $\mathcal{W} \neq \emptyset$ y $\mathcal{S} \neq \emptyset$; además, $\mathcal{I} \neq \emptyset$ si y solo si $h > h_0 \in (0, 1)$.

El salario w es continuo, estrictamente creciente y convexo, con

$$w(z) = m(z) - \frac{w(m(z))}{n(z)} \quad (z \in \mathcal{W}), \quad w(z) = z \quad (z \in \mathcal{I}), \quad w(z) = C + \int_{\inf \mathcal{S}}^z n(e(u)) du \quad (z \in \mathcal{S}).$$

En todo el paper se asume $h < h_0$, es decir, **sin productores independientes antes de la IA**. Entonces $\mathcal{W} = [0, \tilde{z}]$ y $\mathcal{S} = [\tilde{z}, 1]$.

4.1 De dónde sale cada pieza

(a) Salario de los solucionadores: una condición de primer orden. Una firma que ya contrató $n(z)$ trabajadores z elige a su solucionador:

$$\max_{s \in \mathcal{S}} n(z) [s - w(z)] - w(s).$$

La CPO en $s = m(z)$ es $w'(m(z)) = n(z)$. Es decir, **el salario marginal de un solucionador es el tamaño de su equipo**: un poco más de conocimiento en el solucionador sube la probabilidad de éxito en *cada uno* de sus $n(z)$ problemas. Escrito en términos del solucionador, $w'(s) = n(e(s))$, e integrando se obtiene la fórmula de la proposición.

(b) Salario de los trabajadores: beneficio cero. Con $\Pi_2^{nA} = 0$ y $s = m(z)$ se despeja $w(z) = m(z) - w(m(z))/n(z)$. El trabajador se queda con *lo que sobra* de su producción por cabeza, $m(z)$, una vez que se paga la parte que le toca del salario del jefe, $w(m(z))/n(z)$.

(c) Restricción de recursos del matching. El tiempo que piden los trabajadores en $[0, z]$ debe ser igual a la masa de solucionadores que los atienden:

$$\int_0^z h(1-u) dG(u) = G(m(z)) - G(\tilde{z}). \quad (4)$$

Derivando respecto a z : $h(1-z)g(z) = g(m(z))m'(z)$.

(d) La constante C : continuidad. $C = w(\tilde{z})$ se fija para que el salario sea continuo en la frontera $\tilde{z}$ (si hubiera un salto, las firmas contratarían del lado barato). Con $h < h_0$ se cumple $C > \tilde{z}$: el solucionador marginal gana más que lo que produciría solo.

4.2 Una identidad útil

Combinando (a) y (c):

$$\frac{d}{dz} w(m(z)) = w'(m(z)) m'(z) = n(z) \cdot \frac{h(1-z)g(z)}{g(m(z))} = \frac{g(z)}{g(m(z))}. \quad (5)$$

Con conocimiento uniforme, **el salario del jefe de z sube uno a uno con z** : $w(m(z)) = C + z$.

4.3 Ejemplo resuelto: G uniforme y $h = 1/2$

Este es exactamente el caso de las figuras del paper.

Paso 1. Matching. Con $g \equiv 1$, (4) da $m(z) = \tilde{z} + h\left(z - \frac{z^2}{2}\right)$.

Paso 2. Frontera. El trabajador más sabio va con el solucionador más sabio: $m(\tilde{z}) = 1$, o sea

$$\tilde{z} + h\left(\tilde{z} - \frac{\tilde{z}^2}{2}\right) = 1 \xrightarrow{h=1/2} \tilde{z}^2 - 6\tilde{z} + 4 = 0 \implies \tilde{z} = 3 - \sqrt{5} \approx 0.764.$$

Paso 3. Salario del solucionador más sabio. Por (5), $w(1) = w(m(\tilde{z})) = C + \tilde{z}$.

Paso 4. Continuidad en $\tilde{z}$. Por (b) en $z = \tilde{z}$: $C = w(\tilde{z}) = 1 - w(1)h(1 - \tilde{z}) = 1 - (C + \tilde{z})h(1 - \tilde{z})$, de donde

$$C = \frac{1 - \tilde{z}h(1 - \tilde{z})}{1 + h(1 - \tilde{z})} \approx 0.814.$$

Paso 5. Salarios. Para $z \in \mathcal{W}$: $w(z) = m(z) - (C + z)h(1 - z)$. En particular,

$$\boxed{w(0) = \tilde{z} - hC \approx 0.357, \quad w(1) = C + \tilde{z} \approx 1.578}$$

que coinciden con los valores 0.36 y 1.58 de la Figura 3(a) del paper.

Ojo. El número $w(0) \approx 0.357$ va a reaparecer: en la Proposición 6, una IA *no autónoma* se usa si y solo si $z_{AI} > w(0)$. Que este número se pueda calcular a mano es lo que lo vuelve un buen candidato para la derivación manuscrita y para Lean.

4.4 Dos lecturas económicas que usaremos después

1. **Efecto *match*.** El salario de un trabajador depende de con quién lo emparejan: su productividad es $m(z)$. Si la IA le asigna un jefe peor, su salario tiende a caer.
2. **Efecto *share*.** Dado el equipo, la producción se reparte según las escaseces relativas: el trabajador recibe $m(z) - w(m(z))/n(z)$. Si el salario del jefe cae (por ejemplo, porque ahora compite con la IA), el trabajador se queda con una tajada mayor.

Toda la Proposición 5 es una pelea entre estos dos efectos.

Ejercicio 1. Verifica que $w(z) = m(z) - (C + z)h(1 - z)$ es creciente en $[0, \bar{z}]$ cuando $h = 1/2$. ¿Qué parte del argumento usa que g sea uniforme?

Ejercicio 2. Muestra que el valor marginal del conocimiento de un trabajador es menor que 1 (su conocimiento solo “libera” tiempo del jefe), mientras que el de un solucionador es $n(e(s)) > 1$. ¿Por qué esto implica $\mathcal{W} \preceq \mathcal{S}$?

Part II

La IA autónoma: Proposiciones 2, 3 y 4

5 Qué agrega la IA al modelo

La IA es una tecnología que convierte *compute* en “agentes de IA” idénticos, cada uno con conocimiento $z_{AI} \in [0, 1)$ y cada uno consumiendo una unidad de compute. Un agente de IA es un **sustituto perfecto** de un humano con conocimiento z_{AI} . Tres supuestos hacen todo el trabajo:

- (i) **Escalabilidad:** una vez que el conocimiento z_{AI} está en el modelo, se replica en todo el compute disponible. La IA no es “un humano más”; es un tipo de conocimiento con oferta elástica.
- (ii) **Autonomía** (en esta parte): los agentes pueden ser co-trabajadores *y* co-pilotos.
- (iii) **Compute abundante** respecto del tiempo humano: hay más agentes de IA de los que se pueden emparejar con humanos, así que **algo de compute termina produciendo de forma independiente**.

El supuesto (iii) es el que fija el precio. Si una firma automatizada de una capa produce z_{AI} y debe ganar cero,

$$\boxed{r^* = z_{AI}} \quad (6)$$

El alquiler del compute es igual a lo que la IA produce sola. Y como el humano con conocimiento z_{AI} es sustituto perfecto de la IA, $w^*(z_{AI}) = z_{AI}$: **ese humano cae exactamente sobre la recta de 45°**. Antes de la IA ganaba $w(z_{AI}) > z_{AI}$, así que *siempre pierde*. Esa es la primera consecuencia distributiva del modelo y no depende de nada más.

6 Proposición 2: el equilibrio con IA autónoma

Proposición 2 (Prop. 2). *Con IA autónoma existe un único equilibrio, eficiente, con estratificación ocupacional $\mathcal{W}^* \preceq \mathcal{I}^* \preceq \mathcal{S}^*$, emparejamiento positivo, y además:*

$$\mathcal{W}^* \preceq \{z_{AI}\} \preceq \mathcal{S}^*, \quad \mathcal{W}_a^* \preceq \mathcal{W}_p^*, \quad \mathcal{S}_p^* \preceq \mathcal{S}_a^*.$$

La IA siempre se usa en producción independiente; se usa además como trabajadora si $z_{AI} \in \mathcal{W}$ y como solucionadora si $z_{AI} \in \mathcal{S}$. Los precios son $r^ = z_{AI}$ y*

$$w^*(z) = \underbrace{z_{AI} \left(1 - \frac{1}{n(z)}\right)}_{z \in \mathcal{W}_a^*}, \quad \underbrace{m^*(z) - \frac{w^*(m^*(z))}{n(z)}}_{z \in \mathcal{W}_p^*}, \quad \underbrace{\underbrace{z}_{z \in \mathcal{I}^*}}_{z \in \mathcal{S}_p^*}, \quad \underbrace{C^* + \int_{\inf \mathcal{S}_p^*}^z n(e^*(u)) du}_{z \in \mathcal{S}_p^*}, \quad \underbrace{n(z_{AI})(z - z_{AI})}_{z \in \mathcal{S}_a^*},$$

con $C^* = \inf \mathcal{S}_p^*$.

6.1 De dónde sale cada fórmula

Humanos que trabajan bajo un jefe de IA ($z \in \mathcal{W}_a^*$). La firma “top-automatizada” alquila un agente de IA como solucionador y contrata $n(z)$ humanos:

$$n(z)[z_{AI} - w^*(z)] - r^* = 0 \xrightarrow{r^* = z_{AI}} w^*(z) = z_{AI} \left(1 - \frac{1}{n(z)}\right) = z_{AI}(1 - h(1 - z)).$$

Humanos que supervisan trabajadores de IA ($z \in \mathcal{S}_a^*$). La firma “bottom-automatizada” alquila $n(z_{AI})$ agentes como trabajadores y contrata un humano como solucionador:

$$n(z_{AI})[z - r^*] - w^*(z) = 0 \implies w^*(z) = n(z_{AI})(z - z_{AI}).$$

Intuición. Las dos fórmulas son la misma idea vista desde dos lados. El precio de la IA es z_{AI} y, por competencia, todo el excedente que la IA no se lleva va al humano del equipo. Nota que ambas son *lineales* en z : la IA, al tener oferta elástica, ancla el reparto.

Por qué $C^* = \inf \mathcal{S}_p^*$. Pre-IA la constante C era estrictamente mayor que $\inf \mathcal{S}$ (el solucionador marginal ganaba una renta). Post-IA siempre hay producción independiente en la economía, así que el salario debe ser continuo con la recta de 45° en el borde: el solucionador marginal gana exactamente lo que produciría solo. **Esa renta perdida es el “efecto share” que beneficiará a los de abajo.**

6.2 Por qué la IA no puede quedarse fuera de las organizaciones

Un argumento por contradicción que vale la pena entender, porque es el corazón de la parte dos de la proposición. Supón $z_{AI} \in \mathcal{W}$ y que la IA *no* se usa como trabajadora. Entonces la IA tampoco interactúa con humanos, los humanos se emparejan igual que antes y los salarios serían los pre-IA. Pero entonces $w^*(z_{AI}) = w(z_{AI}) > z_{AI}$, y eso contradice que el humano z_{AI} compita con un sustituto perfecto que cuesta z_{AI} . Si la IA no es trabajadora, tendría que ser solucionadora, pero entonces la economía tendría más solucionadores y menos trabajadores que antes, y el mercado no vacía.

7 Ejemplo resuelto: IA básica con G uniforme y $h = 1/2$

Tomamos $z_{AI} = 0.425 \in \text{int } \mathcal{W}$ (recuerda: $\mathcal{W} = [0, 0.764]$ pre-IA). Suponemos la configuración de la Figura 4(a) del paper: la IA se usa como trabajadora y como productora independiente, pero no como solucionadora ($\mathcal{W}_a^* = \emptyset$). La economía humana queda partida en cuatro tramos:

$$\mathcal{W}_p^* = [0, z_1], \quad \mathcal{I}^* = [z_1, z_2], \quad \mathcal{S}_p^* = [z_2, z_3], \quad \mathcal{S}_a^* = [z_3, 1].$$

Las tres ecuaciones. Con $g \equiv 1$:

$$m^*(z) = z_2 + h\left(z - \frac{z^2}{2}\right), \quad (\text{restricción de recursos, igual que antes}) \quad (7)$$

$$w^*(m^*(z)) = z_2 + z, \quad (\text{identidad (5) con } C^* = z_2) \quad (8)$$

$$w^*(z) = m^*(z) - (z_2 + z)h(1 - z), \quad z \in \mathcal{W}_p^*. \quad (9)$$

Las incógnitas z_1, z_2, z_3 salen de tres condiciones de continuidad y emparejamiento:

- (a) continuidad en z_1 con la recta de 45°: $w^*(z_1) = z_1$;
- (b) el mejor trabajador humano va con el mejor solucionador humano “de a pie”: $m^*(z_1) = z_3$;
- (c) continuidad en z_3 con la rama de los que supervisan IA: $z_2 + z_1 = n(z_{AI})(z_3 - z_{AI})$.

Solución numérica ($h = 1/2$, $z_{AI} = 0.425$).

$$z_1 = 0.425 = z_{AI}, \quad z_2 \approx 0.533, \quad z_3 \approx 0.700,$$

$$w^*(0) \approx 0.267, \quad w^*(1) = n(z_{AI})(1 - z_{AI}) = \frac{1}{h} = 2.$$

Ambos números son exactamente los que aparecen en las Figuras 4(a) y 5(a) del paper (0.267 y 2), lo que confirma que nuestra lectura del equilibrio es la correcta.

Ojo. Dos resultados para memorizar, porque reaparecen en la Proposición 5:

- **Arriba:** $w^*(1) = n(z_{AI})(1 - z_{AI}) = 1/h$ sin importar z_{AI} . Con $h = 1/2$ eso es $2 > 1.578 = w(1)$. El humano más sabio siempre gana con IA autónoma.
- **Abajo:** con $z_{AI} = 0.425$, $w^*(0) = 0.267 < 0.357 = w(0)$. El humano menos sabio pierde. Pero si la IA fuese lo bastante buena como para ser *solucionadora* de los de abajo, su salario sería $w^*(0) = z_{AI}(1 - h)$, que crece con z_{AI} . Ahí está el umbral de la Proposición 5.

8 Proposición 3: la IA reordena las ocupaciones

Proposición 3 (Prop. 3). *Si $z_{AI} \in \text{int}\mathcal{W}$ (IA básica), entonces $\mathcal{W}^* \subset \mathcal{W}$ y $\mathcal{S}^* \supset \mathcal{S}$: la IA empuja humanos del trabajo rutinario hacia la resolución de problemas. Si $z_{AI} \in \text{int}\mathcal{S}$ (IA avanzada), ocurre lo contrario: $\mathcal{W}^* \supset \mathcal{W}$ y $\mathcal{S}^* \subset \mathcal{S}$.*

Intuición. La IA es un insumo barato y abundante en el tramo donde cae su conocimiento. Si es básica, abarata el trabajo rutinario; entonces sobran trabajadores (humanos + IA) y falta quien los supervise, así que los trabajadores marginales suben a solucionadores. Si es avanzada, abarata la supervisión y pasa lo contrario: los solucionadores marginales bajan a trabajar.

En nuestro ejemplo numérico se ve directo: pre-IA los trabajadores eran $[0, 0.764]$ y post-IA son $[0, 0.425]$; los solucionadores pasan de $[0.764, 1]$ a $[0.533, 1]$.

9 Proposición 4: qué pasa con los que no cambian de ocupación

Definiciones: la *productividad* de un trabajador es su producto esperado por unidad de tiempo, que es el conocimiento de su jefe, $m(z)$. El *tramo de control* de un solucionador es el número de trabajadores que supervisa, creciente en el conocimiento de esos trabajadores.

Proposición 4 (Prop. 4). • *Si $z_{AI} \in \text{int}\mathcal{W}$: la productividad de todo $z \in \mathcal{W}^* \subset \mathcal{W}$ cae. El tramo de control de $z \in \mathcal{S} \subset \mathcal{S}^*$ crece si $e(z) < z_{AI}$ y cae si $e(z) > z_{AI}$.*

- *Si $z_{AI} \in \text{int}\mathcal{S}$: la productividad de $z \in \mathcal{W} \subset \mathcal{W}^*$ sube si $z < e(z_{AI})$ y cae si $z > e(z_{AI})$. El tramo de control de todo $z \in \mathcal{S}^* \subset \mathcal{S}$ crece.*

Intuición. Con IA básica pasan dos cosas a la vez: (i) los agentes de IA son *los mejores trabajadores* de la economía post-IA, así que por emparejamiento positivo se llevan a los mejores jefes; y (ii) entran solucionadores nuevos, menos sabios que los de antes. Las dos empeoran el jefe disponible para los humanos que siguen de trabajadores. En cambio, los solucionadores de abajo mejoran: ahora supervisan a los trabajadores de abajo, que antes atendían jefes peores.

El paper conecta esto con evidencia anecdótica: en bancos de inversión, los analistas junior quedan cada vez más lejos de los socios senior a medida que la IA absorbe tareas que antes los involucraban (Beane y Anthony, 2024). Es exactamente “la productividad de los que siguen de trabajadores cae porque sus jefes se fueron a supervisar IA”.

Ejercicio 3. En el ejemplo numérico, ¿cuál es el jefe pre-IA y post-IA del trabajador $z = 0.2$? Calcula $m(0.2)$ y $m^*(0.2)$ y verifica que la productividad cae.

Ejercicio 4. Muestra que $w^*(1) = 1/h$ para cualquier z_{AI} en el caso en que la IA se usa como trabajadora. ¿Por qué el resultado no depende de z_{AI} ? (Pista: $n(z_{AI})(1 - z_{AI})$.)

Part III

Proposición 5: ¿quién gana con la IA autónoma?

10 El enunciado

Definimos los ganadores por debajo y por encima de z_{AI} :

$$B \equiv \{z \in [0, z_{AI}] : w^*(z) > w(z)\}, \quad T \equiv \{z \in [z_{AI}, 1] : w^*(z) > w(z)\}.$$

El paper muestra (apéndice online) que $B = [0, z_b]$ y $T = (z_t, 1]$: **los ganadores están siempre en los extremos**. Por eso basta mirar a $z = 0$ y $z = 1$.

Proposición 5 (Prop. 5). *Hay ganadores abajo si la IA es lo bastante buena: $B \neq \emptyset$ si y solo si $z_{AI} > \bar{z}_{AI}$, con $\bar{z}_{AI} \in \text{int}\mathcal{W}$. En cambio, siempre hay ganadores arriba: $T \neq \emptyset$ para todo $z_{AI} \in [0, 1]$.*

11 Los dos efectos

Para cualquier z , el salario se puede leer como “con quién trabajo” por “cuánto me llevo”:

$$w(z) = \underbrace{m(z)}_{\text{efecto match}} - \underbrace{\frac{w(m(z))}{n(z)}}_{\text{efecto share}}.$$

Abajo ($z = 0$), con IA básica.

- *Match* negativo: por la Proposición 4, el jefe del trabajador menos sabio empeora ($m^*(0) < m(0)$), porque entraron solucionadores nuevos menos sabios.
- *Share* positivo: pre-IA el solucionador marginal cobraba una renta ($C > \inf \mathcal{S}$); post-IA cobra exactamente lo que produciría solo ($C^* = \inf \mathcal{S}_p^*$), porque compite con la IA. Esa renta que pierde el jefe se la queda el trabajador.

El signo neto depende de z_{AI} , y ahí aparece el umbral.

Arriba ($z = 1$). También hay un efecto *match* negativo (el humano más sabio termina supervisando agentes de IA, que saben menos que los humanos que supervisaba antes) y uno *share* positivo. Pero el positivo **siempre** gana, y la razón es el tamaño del equipo: como $h < h_0$, cada solucionador supervisa muchos trabajadores, así que una caída pequeña en el salario de cada trabajador se multiplica por $n(\cdot)$ en el bolsillo del jefe.

12 El umbral, en forma cerrada

Aquí es donde nuestro ejemplo uniforme paga. Recuerda de la Parte II que, cuando la IA es lo bastante buena como para usarse *también como solucionadora*, los humanos menos sabios trabajan bajo un jefe de IA y su salario es

$$w^*(0) = z_{AI} \left(1 - \frac{1}{n(0)} \right) = z_{AI} (1 - h).$$

Como el salario pre-IA del mismo individuo es $w(0)$, hay ganadores abajo si y solo si

$$\boxed{z_{AI} > \bar{z}_{AI} = \frac{w(0)}{1 - h}} \quad (10)$$

Con G uniforme y $h = 1/2$: $w(0) \approx 0.357$, así que $\bar{z}_{AI} \approx 0.714$, que en efecto está dentro de $\mathcal{W} = [0, 0.764]$, tal como exige la proposición.

Ojo. El umbral (10) vale en el régimen en que la IA es solucionadora de los de abajo. Nuestras simulaciones (`code/equilibrium.py`) muestran que ese régimen empieza en $z_{AI} = 2/3$, y $2/3 < 0.714$, así que el umbral cae efectivamente dentro de ese régimen. Curiosamente, el valor $2/3$ aparece para todo h que probamos ($h = 0.2, \dots, 0.74$) con G uniforme: es una conjetura que vale la pena demostrar (y un buen candidato para Lean).

Arriba, también en forma cerrada. Si la IA se usa como trabajadora, el humano más sabio supervisa agentes de IA y cobra

$$w^*(1) = n(z_{AI}) (1 - z_{AI}) = \frac{1}{h},$$

independientemente de z_{AI} . Con $h = 1/2$ eso da 2, contra $w(1) \approx 1.578$ pre-IA. El de arriba gana siempre, y gana lo mismo con una IA mediocre que con una casi perfecta.

13 Tabla de resultados (uniforme, $h = 1/2$)

Part IV

Proposición 6 y la trampa: ¿autonomía o capacidad?

14 IA no autónoma: el modelo cambia en un solo supuesto

Ahora los agentes de IA solo pueden aconsejar: son co-pilotos, no co-trabajadores. Las consecuencias son inmediatas:

z_{AI}	configuración	$w^*(0)$	$w^*(1)$	¿ganan abajo?
0.425	IA solo trabajadora	0.267	2.000	no
0.600	IA solo trabajadora	0.319	2.000	no
0.700	IA también solucionadora	0.350	2.000	no
0.720	IA también solucionadora	0.360	2.000	sí
0.850	IA también solucionadora	0.425	2.000	sí

Tabla 1: Referencia pre-IA: $w(0) \approx 0.357$, $w(1) \approx 1.578$. Los valores 0.267, 0.425 y 2 coinciden con las Figuras 4 y 5 del paper.

- (i) Las firmas de una capa automatizadas y las “bottom-automatizadas” desaparecen: sin capacidad de producir, esos arreglos no generan nada. Quedan tres configuraciones.
- (ii) Parte del compute queda *ocioso*, así que su precio cae a cero: $r^* = 0$.
- (iii) La IA deja de ser sustituto perfecto del humano z_{AI} , así que $w^*(z_{AI}) \neq r^*$. El humano z_{AI} ya no queda clavado sobre la recta de 45°.

El salario de los de abajo, en una línea. Una firma con un solucionador de IA (gratis) y $n(z)$ trabajadores humanos gana cero:

$$n(z) [z_{AI} - w^*(z)] - \underbrace{r^*}_{=0} = 0 \implies \boxed{w^*(z) = z_{AI} \text{ para todo } z \in \mathcal{W}_a^*}$$

El salario es *constante e igual a la capacidad de la IA*: el trabajador se queda con todo el producto esperado del equipo, porque el otro insumo no cuesta nada. Compáralo con el caso autónomo, donde el mismo trabajador cobraba $z_{AI}(1 - h)$: la diferencia es exactamente el costo de oportunidad de la IA, que con autonomía es positivo ($r^* = z_{AI}$) y sin autonomía es cero.

Proposición 6 (Prop. 6). *Con IA no autónoma el equilibrio es único, eficiente, maximiza el ingreso laboral y $r^* = 0$. Además:*

- si $z_{AI} \leq w(0)$, la IA **no se usa** y todo queda como antes;
- si $z_{AI} > w(0)$, solo los menos sabios la usan como solucionadora.

En todo caso: (1) el producto total es mayor con IA autónoma; (2) la IA no autónoma crea perdedores; (3) los menos sabios prefieren la IA no autónoma a cualquiera de las otras dos situaciones; (4) los más sabios prefieren la IA autónoma.

De dónde sale $z_{AI} > w(0)$. Trivial con la fórmula anterior: el trabajador menos sabio acepta trabajar bajo un jefe de IA solo si eso le paga más que su salario pre-IA, es decir si $z_{AI} > w(0)$. Con $h = 1/2$ uniforme, el umbral es 0.357.

15 La trampa de la semana

La frase de una línea que circula sobre este paper es: “*el efecto distributivo lo determina la autonomía de la IA, no su capacidad*”. Contrastémosla con las Proposiciones 5 y 6.

	IA autónoma	IA no autónoma
Precio del compute	$r^* = z_{AI}$	$r^* = 0$
Salario de los de abajo	$z_{AI}(1 - h)$ (si la IA los supervisa)	z_{AI} (si la usa)
¿Ganadores abajo?	sí $\iff z_{AI} > \frac{w(0)}{1 - h}$	sí $\iff z_{AI} > w(0)$
Umbral con $h = 1/2$ uniforme	0.714	0.357
¿Ganadores arriba?	siempre	no necesariamente
Producto total	mayor	menor

Tabla 2: Las dos dimensiones: capacidad (z_{AI}) y autonomía.

La respuesta. La condición para que haya ganadores abajo es de capacidad, no de autonomía: en los dos regímenes es un umbral sobre z_{AI} . Lo que hace la autonomía es *mover el umbral y escalar la ganancia*:

$$\bar{z}_{AI}^{\text{autónoma}} = \frac{w(0)}{1 - h} = \frac{1}{1 - h} \cdot \bar{z}_{AI}^{\text{no autónoma}}.$$

Con $h = 1/2$ el umbral se duplica. Dicho de otro modo: quitar autonomía no crea ganadores abajo por sí solo (si $z_{AI} \leq w(0)$ la IA ni siquiera se usa y no cambia nada), y poner autonomía no los elimina por sí sola (si $z_{AI} > 0.714$ los de abajo ganan igual). Lo correcto es:

Si hay ganadores abajo depende de la capacidad; cuánto ganan y quién gana arriba depende de la autonomía.

Dónde sí manda la autonomía. En tres cosas: (i) el producto total, siempre mayor con IA autónoma; (ii) los más sabios, que siempre prefieren la autónoma; y (iii) el tamaño de la ganancia abajo, donde el factor $1 - h$ es el costo de oportunidad de la IA. De ahí el *tradeoff* regulatorio del paper: restringir la autonomía redistribuye hacia abajo, pero reduce el producto.

Ejercicio 5. Con $h = 1/2$ uniforme y $z_{AI} = 0.5$: ¿ganan o pierden los de abajo con IA autónoma? ¿Y con IA no autónoma? Usa $w(0) = 0.357$, $w^*(0)$ de la tabla de la Parte III y $w^*(0) = z_{AI}$.

Ejercicio 6. Muestra que el cociente entre los dos umbrales es $1/(1 - h)$ y explica en palabras por qué el costo de oportunidad de la IA aparece ahí.